

江烟 拓哉¹

2018-12-12 Wed

研究概要

先行研究

想定する対話システムの
概要図

日本語データの取り扱い
について

文抽出を念頭においた不
均衡分散・サイズの分類
問題

機械翻訳モデルを用いた
対話モデル

文のスタイル変換

CoLA タスクを応用した
対話システムのエラー
検知

結論

References

Outline

研究概要

先行研究

想定する対話システムの概要図

日本語データの取り扱いについて

文抽出を念頭においた不均衡分散・サイズの分類問題

機械翻訳モデルを用いた対話モデル

文のスタイル変換

CoLA タスクを応用した対話システムのエラー検知

結論

研究概要

先行研究

想定する対話システムの
概要図日本語データの取り扱い
について文抽出を念頭においた不
均衡分散・サイズの分類
問題機械翻訳モデルを用いた
対話モデル

文のスタイル変換

CoLA タスクを応用した
対話システムのエラー
検知

結論

References

昨今自然言語処理において対話システムを構築する試みを様々な団体が行っている。本研究ではその流れに乗り、特にキャラクターのある日本語を用いた対話システムの構築を目指す。

尚対話システムを構築する手法として、複数の小さな問題に分割して解決するというものがある。本研究ではその手法を採用し、複数の小問題を設定し、それぞれについて研究を行った。

更に学習データである日本語データについて収集を行い、そのデータの性質・考えられる前処理手法を調査した。



Figure: イメージ

研究概要

先行研究

想定する対話システムの
概要図

日本語データの取り扱い
について

文抽出を念頭においた不
均衡分散・サイズの分類
問題

機械翻訳モデルを用いた
対話モデル

文のスタイル変換

CoLA タスクを応用した
対話システムのエラー
検知

結論

References

先行研究としては、Microsoft 社の女子高生 AI「りんな」(Wo et al. 2016) の他、Amazon Alexa Prize という Amazon Alexa の内部システムについてのコンテストにおける作品 (Chen et al. 2018 や Fang et al. 2018) を挙げることが出来る。

以下のようなシステムを想定し、それぞれに必要なになるテーマのうちの5つを本研究では取り上げ研究を行った。

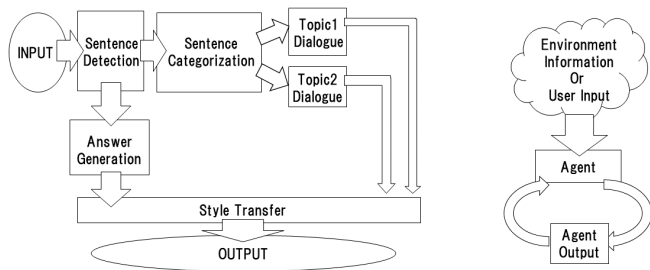


Figure: 本研究のシステム全体像

研究概要

研究概要

先行研究

想定する対話システムの
概要図日本語データの取り扱い
について文抽出を念頭においた不
均衡分散・サイズの分類
問題機械翻訳モデルを用いた
対話モデル

文のスタイル変換

CoLA タスクを応用した
対話システムのエラー
検知

結論

References

特に日本語の自然言語処理を研究する際に、その利用可能なデータが少ない、最適な前処理手法が確立されていないという問題がある。

本テーマでは、対話システムを構築することを前提に、まず Twitter のデータ、NTT の雑談対話コーパス、名大コーパスのデータを観察し、どのようなデータがあるのかを調査し、次に Wikipedia コーパスをデータとして、前処理 漢字 → かな変換 を行い、単語分散を得、その効果を実験した。

結果 1) データの調査

研究概要

先行研究

想定する対話システムの
概要図日本語データの取り扱い
について文抽出を念頭においた不
均衡分散・サイズの分類
問題機械翻訳モデルを用いた
対話モデル

文のスタイル変換

CoLA タスクを応用した
対話システムのエラー
検知

結論

References

- ▶ Twitter データについてはテキストを通じた日常的な対話、発話が直に得られたものの、絵文字・顔文字についての処理について深く踏み込まなければならないこと、データの偏りが大きいことがわかった。
- ▶ 名大コーパスについては現実の音声会話であるため、テキストの対話システムを構築するデータとしてはやや不適であると考えられた。
- ▶ NTT の雑談対話コーパスについては対話システムのログから得られたデータであったため、本研究のためのデータとして直ちに有効であるとわかった。

結果2) 日本語データの前処理手法の提案

研究概要

先行研究

想定する対話システムの
概要図日本語データの取り扱い
について文抽出を念頭においた不
均衡分散・サイズの分類
問題機械翻訳モデルを用いた
対話モデル

文のスタイル変換

CoLA タスクを応用した
対話システムのエラー
検知

結論

References

- ▶ 漢字 → かな 変換を行ったことで、語彙数の減少は見られたが、単語分散を獲得する学習 (fasttext (Bojanowski et al. 2017) を用いた) で損失が増えてしまうという問題が発生した。しかし得られた単語分散で極性判定を行った (CNN-LSTM (Sainath et al. 2015) を用いた) ところ、いずれも性能はほとんど変わらなかった。
- ▶ 単語分散を用いてある単語の類似単語を調査したところ、変換をした場合は音声的に近い単語を類似単語として集めることが出来た。

研究概要

研究概要

先行研究

想定する対話システムの
概要図日本語データの取り扱い
について文抽出を念頭においた不
均衡分散・サイズの分類
問題機械翻訳モデルを用いた
対話モデル

文のスタイル変換

CoLA タスクを応用した
対話システムのエラー
検知

結論

References

対話システムを構築する上で、任意の入力に対していくつかの特定のクラス (ex. 質問や注文) に属しているか、或いはどのクラスにも属していないのかを判定したい、という場面が出てくる。この場면을想定した場合に、一般的なクラス分類では困難であることが伺える。本テーマではこの問題に対して、まず文の類似度を学習し、次に入力文に対して各クラスのサンプルを数個用いてそれぞれの類似度を測り、その要約統計を取ることで入力があるどのクラスに所属しているのかを判定する手法を提案する。

結果

BERT(Bidirectional Encoder Representations from Transformers Devlin et al. 2018) と呼ばれる言語モデルを文類似度を測るようにファインチューニングした。データには各クラスを設定し、それぞれに学習データを平均7文作成し、各文の組み合わせを取ったものを用いた。ここにおける正答率 (accuracy) は 96 %、損失 (cross-entropy) は 0.132 と良い成績を得ることが出来た。

しかしクラス分類を行った際に要約統計を行ったところ、同じカテゴリ (例えば天候に関するカテゴリ) に属するようなクラスの文うまく分類できなかった。原因としては組み合わせを用いてデータを作成した際に、負のサンプルを正のサンプル数と揃えるため切り落としたこと、クラス外のデータを用意できなかったことが考えられる。

研究概要

先行研究

想定する対話システムの概要図

日本語データの取り扱いについて

文抽出を念頭においた不均衡分散・サイズの分類問題

機械翻訳モデルを用いた対話モデル

文のスタイル変換

CoLA タスクを応用した対話システムのエラー検知

結論

References

研究概要

先行研究

想定する対話システムの
概要図日本語データの取り扱い
について文抽出を念頭においた不
均衡分散・サイズの分類
問題機械翻訳モデルを用いた
対話モデル

文のスタイル変換

CoLA タスクを応用した
対話システムのエラー
検知

結論

References

赤が正解 (嫌いな食べ物を尋ねる) で、紫が予測 (好きな食べ物を尋ねる) である。

縦軸は要約統計 (平均)
を取った類似度であり、
横軸はそれぞれのク
ラスの id を示している。
このことから、キー
ワードを用いた分類も
判定材料に加えた方が
良いと考えられる。




Figure: うまくいかなかった例

研究概要

研究概要

先行研究

想定する対話システムの
概要図日本語データの取り扱い
について文抽出を念頭においた不
均衡分散・サイズの分類
問題機械翻訳モデルを用いた
対話モデル

文のスタイル変換

CoLA タスクを応用した
対話システムのエラー
検知

結論

References

昨今の自然言語処理の、特に機械学習 (深層学習) を用いる界限では、機械翻訳モデルの研究が盛んである。この分野で得られたモデルを対話システムの、特に反射応答、常識的な応答に対して用いようというのが本テーマのモチベーションである。本テーマでは特に古くから用いられている Sequence to Sequence Attention (Luong, Pham, and Manning 2015) と最近登場し注目を浴びている Transformer (Vaswani et al. 2017) の2つのモデルを用いて実験を行った。

結果

Sequence to Sequence Attention モデルに対して Transformer は実行時間や計算コストが低く、BLEU スコア (主に機械翻訳などの自然言語処理で用いられる精度指標) が高いことがわかった。

Table: 学習に用いたデータの BLEU スコア

	BLEU スコア
Seq2Seq Attn	66.92
Transformer	77.11

Table: 学習外のデータについての BLEU スコア

	BLEU スコア
Seq2Seq Attn	61.80
Transformer	64.33

研究概要

先行研究

想定する対話システムの
概要図

日本語データの取り扱い
について

文抽出を念頭においた不
均衡分散・サイズの分類
問題

機械翻訳モデルを用いた
対話モデル

文のスタイル変換

CoLA タスクを応用した
対話システムのエラー
検知

結論

References

Table: データセットの入力と出力の例

入力	出力
<p>チーズケーキは好きですね。 おはよー。熱中症に気をつけて。 テレビは民主党支持が多いですね。 プレイは普通です。 晴れの日は嫌い?暑い? ですよ。</p>	<p>チーズケーキの美味しい店を知っています。 おはようございます。 そんな事はないでしょ? どんなスポーツをされますか? 晴れの日がいいですね。 はい。</p>

Table: Sequence to Sequence Attention と Transformer によって得られた出力

Seq2Seq Attn	Transformer
<p>チーズケーキの美味しい店を知っています。 漫画は読みますか。 そんな事はないでしょ? どんなスポーツをされますか? 晴れの日がいいですね。 夏って感じがします。</p>	<p>チーズケーキの美味しい店を知っています。 おはようございます。 そんな事はないでしょ? どんなスポーツをされますか? 晴れの日がいいですね。 私もスポーツが好きです。</p>

研究概要

研究概要

先行研究

想定する対話システムの
概要図日本語データの取り扱い
について文抽出を念頭においた不
均衡分散・サイズの分類
問題機械翻訳モデルを用いた
対話モデル

文のスタイル変換

CoLA タスクを応用した
対話システムのエラー
検知

結論

References

対話システムの開発において“人間らしさ”はユーザに対し親密感を与えることが出来、より円滑なコミュニケーションを促進することが出来ると考えられる。また日本語は英語に比べ、語尾のみの変換でも、比較的にペルソナを象ることが出来ると考えられる形態を持っている。そのため本テーマでは特に語尾を中心とした文のスタイル変換を提案し、これを行うために(英語での)スタイル変換を目的とした Sequence to Better Sequence(Mueller, Gifford, and Jaakkola 2017) というモデルと これに Denoising Autoencoder(Vincent et al. 2008) を加えたモデル、CopyNet(Gu et al. 2016) という機械翻訳・文要約の問題設定で用いられるモデルを用いて実験した。

結果

研究概要

先行研究

想定する対話システムの
概要図日本語データの取り扱い
について文抽出を念頭においた不
均衡分散・サイズ分類
問題機械翻訳モデルを用いた
対話モデル

文のスタイル変換

CoLA タスクを応用した
対話システムのエラー
検知

結論

References

十分なデータを用意することが出来なかったため、Sequence to Better Sequence とこれに Denoising Autoencoder を加えたものの結果に有意な差を見ることが出来なかった。こちらは語尾のみの変換にとどまらず文全体も変換するという結果が得られ、大規模なデータを用いた場合の更なる興味深い結果を期待できる。

CopyNet については語彙外の単語に対してもほとんど適切に (そのまま出力に受け流すという形で) 対処することが出来た。

研究概要

先行研究

想定する対話システムの
概要図日本語データの取り扱い
について文抽出を念頭においた不
均衡分散・サイズの分類
問題機械翻訳モデルを用いた
対話モデル

文のスタイル変換

CoLA タスクを応用した
対話システムのエラー
検知

結論

References

Table: 文スタイル変換の実験結果

実装	入力	出力
S2BS	おはようございます。 応援する。 今日は寒かった。 夕飯は？ 早く寝たい。 何か不安だなあ。	おはよう。 応援してる。 今日は寒かった。 夕飯はどうでしょうか？ お風呂に入ろう。 何か口に入れてはどうでしょうか
S2BS with DAE	S2BS と同じ結果が得られた	
CopyNet	おはようございます。 今日は良い天気ですね。 こんにちは。 頑張るぞい！ 進捗どうですか？	おはよう。 今日は良い天気。 こんにちは。 頑張るぞい！ 進捗どう？

研究概要

研究概要

先行研究

想定する対話システムの
概要図日本語データの取り扱い
について文抽出を念頭においた不
均衡分散・サイズの分類
問題機械翻訳モデルを用いた
対話モデル

文のスタイル変換

CoLA タスクを応用した
対話システムのエラー
検知

結論

References

深層学習をはじめとした機械学習を用いた文生成においてはその精度が不安要素として挙げられる。本テーマでは特に機械学習モデルから生成されてしまった不自然な文を特定することを扱い、その後の何らかのエラー処理 (例えばその生成文に代わって“よくわかりません”とするなど) に繋げる足がかりとする。

結果

研究概要

先行研究

想定する対話システムの
概要図日本語データの取り扱い
について文抽出を念頭においた不
均衡分散・サイズの分類
問題機械翻訳モデルを用いた
対話モデル

文のスタイル変換

CoLA タスクを応用した
対話システムのエラー
検知

結論

References

BERT と呼ばれる言語モデルを自然な文と自然でない文の2値分類するようにファインチューニングした。データには 機械翻訳モデルを用いた対話モデル で得られた出力を手動でラベリングしたものを用いた。結果としては正答率 (accuracy) が 61 % 損失が (cross-entropy) 0.712082 であったが、自然な文と自然でない文を2値分類する問題の中では優秀な精度を得られた。但し難しい学習であったためか、学習がやや不安定になっていることが確認された。

研究概要

先行研究

想定する対話システムの
概要図日本語データの取り扱い
について文抽出を念頭においた不
均衡分散・サイズの分類
問題機械翻訳モデルを用いた
対話モデル

文のスタイル変換

CoLA タスクを応用した
対話システムのエラー
検知

結論

References




Figure: 対話システムのエラー検知の実験結果 における epoch と 精度の変化

研究概要

先行研究

想定する対話システムの
概要図日本語データの取り扱い
について文抽出を念頭においた不
均衡分散・サイズの種類
問題機械翻訳モデルを用いた
対話モデル

文のスタイル変換

CoLA タスクを応用した
対話システムのエラー
検知

結論

References

必要な要素それぞれにを大まかに総括すれば、用意できたデータ数を考慮すれば、十分な結果であったと考えられる。しかしこれが大規模なデータに対してどのような結果になるのかは未知数であるし、そもそも第規模なデータを確保できるかも不明である。その点から本研究では取り扱わなかったルールベースのような技術も取り込む必要があると考えられる。

また本研究では扱わなかった分野の研究や、各テーマで考察された新たな問題に対しても研究する必要がある。

- Bojanowski, Piotr et al. (2017). “Enriching Word Vectors with Subword Information”. In: *TACL* 5, pp. 135–146.
- Chen, Chun-Yen et al. (2018). *Gunrock: Building A Human-Like Social Bot By Leveraging Large Scale Real User Data*.
- Devlin, Jacob et al. (2018). “BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding”. In: *CoRR* abs/1810.04805.
- Fang, Hao et al. (2018). *Sounding Board: A User-Centric and Content-Driven Social Chatbot*. eprint: arXiv:1804.10202.
- Gu, Jiatao et al. (2016). “Incorporating Copying Mechanism in Sequence-to-Sequence Learning”. In: *CoRR* abs/1603.06393.
- Luong, Thang, Hieu Pham, and Christopher D. Manning (2015). “Effective Approaches to Attention-based Neural Machine Translation”. In: *EMNLP*.
- Mueller, Jonas, David Gifford, and Tommi Jaakkola (Aug. 2017). “Sequence to Better Sequence: Continuous

研究概要

先行研究

想定する対話システムの
概要図日本語データの取り扱い
について文抽出を念頭においた不
均衡分散・サイズの分類
問題機械翻訳モデルを用いた
対話モデル

文のスタイル変換

CoLA タスクを応用した
対話システムのエラー
検知

結論

References

Revision of Combinatorial Structures”. In: *Proceedings of the 34th International Conference on Machine Learning*. Ed. by Doina Precup and Yee Whye Teh. Vol. 70. Proceedings of Machine Learning Research. International Convention Centre, Sydney, Australia: PMLR, pp. 2536–2544. URL: <http://proceedings.mlr.press/v70/mueller17a.html>.

Sainath, Tara N. et al. (2015). “Convolutional, Long Short-Term Memory, fully connected Deep Neural Networks”. In: *2015 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*, pp. 4580–4584.

Vaswani, Ashish et al. (2017). “Attention Is All You Need”. In: *NIPS*.

Vincent, Pascal et al. (2008). “Extracting and Composing Robust Features with Denoising Autoencoders”. In: *Proceedings of the 25th International Conference on Machine Learning*. ICML '08. Helsinki, Finland: ACM, pp. 1096–1103. ISBN: 978-1-60558-205-4. DOI:



研究概要

先行研究

想定する対話システムの
概要図

日本語データの取り扱い
について

文抽出を念頭においた不
均衡分散・サイズの分類
問題

機械翻訳モデルを用いた
対話モデル

文のスタイル変換

CoLA タスクを応用した
対話システムのエラー
検知

結論

References

10.1145/1390156.1390294. URL:

<http://doi.acm.org/10.1145/1390156.1390294>.

Wo, Xianchao et al. (Mar. 2016). りんな：女子高生人工
知能. 言語処理学会 第 22 回年次大会 発表論文集.
Microsoft Japan Inc.